

UNIVERSIDAD NACIONAL DE SAN AGUSTÍN DE AREQUIPA  
FACULTAD DE INGENIERÍA DE PRODUCCIÓN Y SERVICIOS  
ESCUELA PROFESIONAL DE CIENCIA DE LA COMPUTACIÓN



**Random Forest para Series Temporales de la Actividad Electrodermica  
de la Piel**

Plan de Tesis presentada por:

Bejar Merma,Angel Andres

Para optar el Título Profesional de:  
Licenciado(a) en Ciencia de la Computación

Asesor:

Apellidos, Nombres

Arequipa - Perú

2023



# Índice general

<b>Abstract</b>	<b>v</b>
<b>1. Introducción</b>	<b>1</b>
1.1. Justificación . . . . .	2
1.2. Relevancia y/o Motivación de la Propuesta . . . . .	3
1.2.1. Definición del Problema . . . . .	4
1.3. Objetivos . . . . .	4
1.3.1. Objetivo General . . . . .	4
1.3.2. Objetivos específicos . . . . .	5
<b>2. Marco teórico</b>	<b>6</b>
2.0.1. SRC y SCL . . . . .	6
<b>3. Estado del Arte</b>	<b>9</b>
3.0.1. Maching Learning . . . . .	9
3.0.2. Por reglas definidas . . . . .	9
3.0.3. Detección de fatiga mediante Gradient Boosting Decision Tree (GBDT) . . . . .	10
3.0.4. Detección de fatiga mediante aprendizaje profundo . . . . .	11
<b>4. Propuesta</b>	<b>13</b>
4.0.1. Preprocesamiento . . . . .	16
4.0.2. Entrenamiento . . . . .	17
4.0.3. Análisis . . . . .	17
<b>5. Experimentos y Resultados</b>	<b>19</b>
5.0.1. Métricas . . . . .	19
<b>6. Conclusiones y trabajo futuro</b>	<b>21</b>
<b>Bibliografía</b>	<b>22</b>

# Índice de figuras

2.1. Visualización de los componentes de un SRC ante un evento .Dawson et al.[Dawson et al,2017]	7
2.2. Señal EDA capturado de la Aplicación Empatica Realtime	7
2.3. Especificaciones técnicas del E4-wristband	8
4.1. dataset work3d	15
4.2. Características	16
5.1. resultados	19
5.2. Ejemplo del <i>aliasing</i> que se produce en una grilla con $N = 8$ nodos. Ambos modos ( $k = 2$ y $k = 10$ ) toman los mismos valores en los puntos de la grilla.	20

# Índice de cuadros

3.1. Resumen de todas las metodologías para la detección de estrés . . . . .	12
4.1. Configuraciones de Grid Search de cinco modelos de Aprendizaje Automático utilizados al entrenar modelos de detección de estrés. . . . .	17

# Resumen

---

El uso de aplicaciones es una parte fundamental de la vida ,sin embargo su uso excesivo , trae como consecuencias estilos de vida poco saludables y puede desencadenar en diversas problemas como problemas al corazón , estrés,fatiga etc. Si bien se han realizado muchas investigaciones utilizando la señal Electrodermica de la piel(EDA) para detectar estrés ,existen pocos trabajos que realicen un análisis estadístico sobre los modelos dependiente y independiente del usuario, en términos de demostrar que los primeros son mas precisos , y no ocurre por casualidad en lo que a estrés concierne . Este trabajo , se centra en realizar un análisis sobre la capacidad de modelos dependientes e independientes del usuario usando Random Forest así como proponer un sistema de detección de estrés ,para ello se utilizara la base de datos WESAD disponibles públicamente que contienen diferentes señales fisiológicas registradas con la pulsera Empatica E4.

# Capítulo 1

## Introducción

---

El estrés es una respuesta natural del cuerpo ante situaciones que percibimos como amenazantes o desafiantes. Esta reacción puede ser de corta duración, conocida como **estrés agudo**, o prolongarse en el tiempo, dando lugar al **estrés crónico**. Ambos tipos de estrés tienen efectos significativos en nuestra salud física y mental, aunque sus manifestaciones y consecuencias pueden variar considerablemente.

El estrés agudo se caracteriza por ser una respuesta inmediata y de corta duración ante un estímulo específico. Es el tipo de estrés que sentimos, por ejemplo, antes de un examen importante o durante una situación de emergencia. Aunque puede ser intenso, el estrés agudo suele desaparecer una vez que la situación estresante ha pasado. Este tipo de estrés puede incluso tener efectos positivos, como mejorar el rendimiento y la concentración en situaciones críticas (Smith, 2020).

Por otro lado, el estrés crónico se desarrolla cuando una persona está expuesta a factores estresantes de manera continua o repetitiva. Este tipo de estrés puede tener efectos perjudiciales a largo plazo, contribuyendo al desarrollo de diversas enfermedades, como trastornos cardiovasculares, problemas digestivos y trastornos de ansiedad (Jones & Brown, 2019). El estrés crónico puede erosionar la salud y el bienestar general, afectando tanto el cuerpo como la mente.

A lo largo de este artículo, exploraremos las características, causas y consecuencias del estrés agudo y su adquisición mediante la señal EDA. Finalmente, nos centraremos

en la detección del estrés agudo utilizando inteligencia artificial, analizando la señal EDA y poder identificar y gestionar eficazmente el estrés agudo proporcionando nuevas herramientas para el bienestar y la salud mental.

## 1.1. Justificación

La detección de estrés agudo es un área de investigación importante y relevante por varias razones:

El estrés en el lugar de trabajo puede afectar significativamente el bienestar del trabajador. Puede llevar a un bajo estado de ánimo y disminución de la atención, lo que puede afectar la calidad de vida del trabajador.

- **Productividad de la empresa:** El estrés no solo afecta al individuo, sino también a la productividad de la empresa. Un trabajador fatigado puede tener un rendimiento reducido, lo que puede afectar la eficiencia y la rentabilidad de la empresa.
- **Seguridad:** El estrés puede aumentar el riesgo de errores y accidentes. En el caso de los conductores, por ejemplo, la fatiga que deriva en estrés es una de las principales causas de accidentes de tránsito.
- **En el campo de la salud:** La detección de estrés agudo es especialmente relevante. Por ejemplo, en pacientes con cáncer, el estrés es un síntoma común que puede afectar en gran medida su vida diaria. Sin embargo, a menudo no se identifica ni se valora adecuadamente, lo que puede resultar en una falta de cuidado y tratamiento adecuados.
- **Investigación en salud:** Por lo tanto, la investigación en la detección de estrés agudo puede tener implicaciones significativas en diversas áreas, desde mejorar la salud y el bienestar de los individuos hasta aumentar la seguridad y la productividad en el lugar de trabajo. Además, puede contribuir a la mejora de las intervenciones y tratamientos en el campo de la salud. Por estas razones, justificar un trabajo de investigación en la detección de fatiga es tanto relevante como necesario.



## 1.2. Relevancia y/o Motivación de la Propuesta

El estrés agudo se caracteriza como una forma de agotamiento objetivo y subjetivo que surge de la participación prolongada en actividades cognitivas [Ishii et al., 2014]. Tiene implicaciones [Grillon et al., 2015], [Brown and Bray, 2019], [Van Cutsem et al., 2017], [Dogan and Akbulut, 2023], [Cropanzano et al., 2003] sobre las emociones, el comportamiento, el bienestar físico y las interacciones sociales. Los efectos abarcan un espectro de emociones, que incluyen rabia y melancolía, así como una renuencia a participar en entornos sociales.

El estrés agudo es uno de los problemas más comunes que ocurren entre los pacientes [Martin et al., 2018], [Marcora et al., 2009], en el que un individuo experimenta resistencia a una actividad [Meijman, 2000], mal Humor [Hockey, 1983] letargo [Martin et al., 2018]. El estrés se relaciona principalmente con la enfermedad, el envejecimiento y la depresión. [Martin et al., 2018].

En situaciones de estrés agudo, se observan modificaciones significativas en las señales físicas, como el ritmo cardíaco, la respiración, la sudoración y la dilatación de las pupilas. En estas situaciones los dispositivos portátiles se pueden aprovechar para capturar las señales a través de sus sensores, uno de ellos es la pulsera E4 wristband que mide diversas señales entre ellas EDA, BVP Figura 2.3.

La señal electrodérmica de la piel (EDA) mide los cambios eléctricos en la superficie de la piel, que surgen cuando la piel recibe señales inervantes del cerebro. Para la mayoría de las personas, si experimentan activación emocional, aumento de la carga cognitiva o esfuerzo físico, su cerebro enviara señales a la piel para aumentar el nivel de sudoración, con ello su posterior registro por medio de los sensores del EDA. Las unidades de medida de la conductancia son microSiemens.

Las causas del estrés agudo pueden ser variadas, pero algunas de las más comunes incluyen:

- **Exceso de trabajo intelectual:** Las personas que tienen un exceso de empleo de tipo intelectual, donde se les exige comprender, razonar, solucionar problemas, estar concentrados y memorizar de forma casi constante, son propensas a la fatiga mental.

- **Ritmo de vida frenético:** El ritmo de vida acelerado, especialmente en las ciudades, puede llevar al estrés mental.
- **Dificultades para gestionar el tiempo y para desconectar:** La incapacidad para manejar adecuadamente el tiempo y desconectar.

### 1.2.1. Definición del Problema

Existen varias limitaciones con respecto a la detección de estrés agudo.

Por ejemplo, en un estudio de laboratorio se encontró que el 22 % de los datos de actividad electrodérmica (EDA) recopilados por un dispositivo portátil eran inutilizables (van Lier et al., 2020), mientras que un estudio ambulatorio que utilizó el mismo dispositivo estimó el 78 % (van Lier et al., 2020).

los modelos genericos random forest

Debido a que el estrés es subjetivo y se expresa de manera diferente de una persona a otra, los modelos genéricos de predicción del estrés tienen bajo rendimiento. Sólo los específicos de una persona (dependientes del usuario) producen predicciones confiables, pero no son adaptables y su implementación en entornos del mundo real es costosa. Así como en un entorno de oficina, un modelo dependiente del usuario requeriría recopilar nuevos datos y entrenar un nuevo modelo para cada empleado. Además, una vez implementados, los modelos se deteriorarían y necesitarían costosas actualizaciones periódicas porque el estrés es dinámico y depende de factores que no se tienen en cuenta .

## 1.3. Objetivos

### 1.3.1. Objetivo General

Diseñar un sistema para el análisis y la detección de estrés agudo usando el modelo Random Forest y Perceptrón Multicapa a partir de la actividad electrodermica de la piel de baja resolución .

Diseñar un modelo un modelo que mejore la precisión de de los modelos genéricos

**1.3.2. Objetivos específicos**

- *Preprocesar los datos*
- *Entrenar el modelo utilizando Random Forest .*
- *Identificar características dominantes*
- Comparar los dos enfoques utilizando señales EDA de baja resolución.
- *Validar la precisión del sistema*

## Capítulo 2

# Marco teórico

---

### 2.0.1. SRC y SCL

La medición de la actividad electrodermica (EDA) se compone de dos partes:

- **El nivel de conductancia tónico de la piel(SCL):**Se muestra en la imagen 2.2 como la señal suave subyacentes que cambia lentamente. Se da en ausencia de cualquier evento ambiental discreto particular o estímulos externos. El nivel de conductancia tónica de la piel puede variar lentamente con el tiempo en un individuo dependiendo de su estado psicológico, hidratación, sequedad de la piel.
- **Respuesta de la Conductancia Cutánea(SRC):** Son aumentos bruscos de la conductancia de la piel , los picos en la Figura 2.1. Se asocian típicamente con eventos a corto plazo y ocurren en presencia de estímulos ambientales discretos: vista, sonido, olfato, procesos cognitivos que preceden a un evento, como anticipación, toma de decisiones, etc.




Figura 2.1: Visualización de los componentes de un SRC ante un evento .Dawson et al.[Dawson et al,2017]




Figura 2.2: Señal EDA capturado de la Aplicación Empatica Realtime



Figura 2.3: Especificaciones técnicas del E4-wristband

## Capítulo 3

# Estado del Arte

---

Existen diversos trabajos en donde se proponen detectar estrés agudo, estos trabajos utilizan diferentes métodos los cuales se pueden implementar a través de modelos matemáticos ,modelos Deep learning ,modelos de Maching Learning.

### 3.0.1. Maching Learning

En [Bai et al., 2021b] hicieron un análisis donde usaron el modelo Random Forest basados en efectos mixtos en donde extrajeron características de cada modalidad para aprovechar la información demográfica y mejorar el rendimiento. Los resultados que obtuvieron con los experimentos del conjunto de datos que recopilaron fueron prometedores. Sugirieron que el ECG(Electrocardiograma) es la señal mas importante en la detección de fatiga.

### 3.0.2. Por reglas definidas

[Devi and Bajaj, 2010] sugirió la técnica FIS (Fuzzy Inference Systems ) para la detección de la fatiga, en la que los estados de la boca y los ojos se utilizaron como entrada , para predecir el estado del conductor ,ya sea peligroso, fatigado o normal. Dividieron los estados oculares en categorías: parpadeo, cerrado o somnoliento. Mientras que los estados de la boca se clasificaron como normales o bostezos. Otra investigación[Sikander and Anwar, 2018] ha tenido en cuenta las características mencionadas

anteriormente y ha desarrollado una técnica para detectar la fatiga utilizando un FIS de dos capas.

En la detección de fatiga mediante aprendizaje automático, existe el trabajo de [Fan et al., 2007] que utilizó el bostezo como parámetro, sugirió un método para rastrear el movimiento de la cara con la ayuda de una cámara. En la técnica (Gravity-Centre) propuesta por el autor para detectar las comisuras de la boca utilizando proyección de grises, extrajo las características de la boca mediante el uso de ondículas de Gabor que produjeron información sobre órganos como los ojos, la nariz, la boca y los labios. utilizaron ondícula de Gabor de representación bidimensional para analizar y procesar la textura de la imagen. Luego, utilizó el análisis discriminante lineal (LDA) para clasificar los vectores de características con el fin de detectar la guiñada.

La técnica que propusieron fue evaluada sobre 400 imágenes y 20 videos que constaban de 4512 rostros. Las características de Gabor fueron capaces de detectar bostezos con una precisión del 96 %, mientras que las características geométricas fueron capaces de detectar bostezos con una precisión del 69,5 %. Finalmente concluyeron que los coeficientes de gabor son más eficientes que las características geométrica.

### **3.0.3. Detección de fatiga mediante Gradient Boosting Decision Tree (GBDT)**

[Hu and Min, 2018] Trató de detectar las características de las señales de EEG, mediante el cálculo de conjuntos de características que incluían las entropías, como una muestra, espectral, difusa y aproximada. Los autores utilizaron la técnica Gradient Boosting Decision Tree (GBDT) basado en una estrategia codiciosa, llamada aumento de gradiente, que tenían como entrada las características de EEG. Para evaluarlo, utilizaron tres clasificadores ampliamente conocidos, a saber, K-vecinos más cercanos (KNN), SVM, ANN para la comparación.

Además, los autores realizaron experimentos en 22 seres humanos. Inicialmente, se les pidió que practicasen la conducción durante varios minutos para familiarizarse con el sistema. La duración de los experimentos realizados fue de unos 40-120 minutos. Los resultados de estos experimentos demostraron que fue posible lograr una precisión de hasta el 95 % para detectar la fatiga mediante EEG.



### 3.0.4. Detección de fatiga mediante aprendizaje profundo

Por otro lado en el aprendizaje profundo [Du et al., 2017] propuso un enfoque multimodal mediante la combinación de EEG y electrooculograma (EOG) para detectar la fatiga. Las señales fisiológicas se utilizaron ampliamente para detectar el estado de los seres humanos. Por medio de la amplitud dedujeron que las señales EOG son más efectivas contra el ruido. Además, los autores introdujeron un modelo multimodal de autoencoder para la detección de fatiga. El modelo que presentaron utilizó señales de EEG y EOG. El experimento se realizó en personas a las que se les pidió que condujeran durante al menos 2 horas, se capturaron las señales de EOG y EEG utilizando un sistema NeuroScan y se utilizó SVM junto con la función de base radial (RBF) como modelo de regresión.

Finalmente la precisión que obtuvieron del modelo auto-encoder multimodal fue de 85 %.

[Rundo et al., 2019] Desarrollo técnicas de última generación para detectar etapas de somnolencia en EEG (la mejor medición fisiológica). Se utilizó un bloque de Transformada de Coseno Discreto (DCT) para realizar la transformación en la frecuencia muestral de EEG. Utilizaron un autoencoder para descubrir patrones de datos no supervisados junto con la reducción de dimensionalidad.

Los resultados que obtuvieron fueron 100 % precisos cuando se probaron en 62 individuos, dominando todas las metodologías anteriores y prometiendo una utilidad en las futuras generaciones de dispositivos médicos.

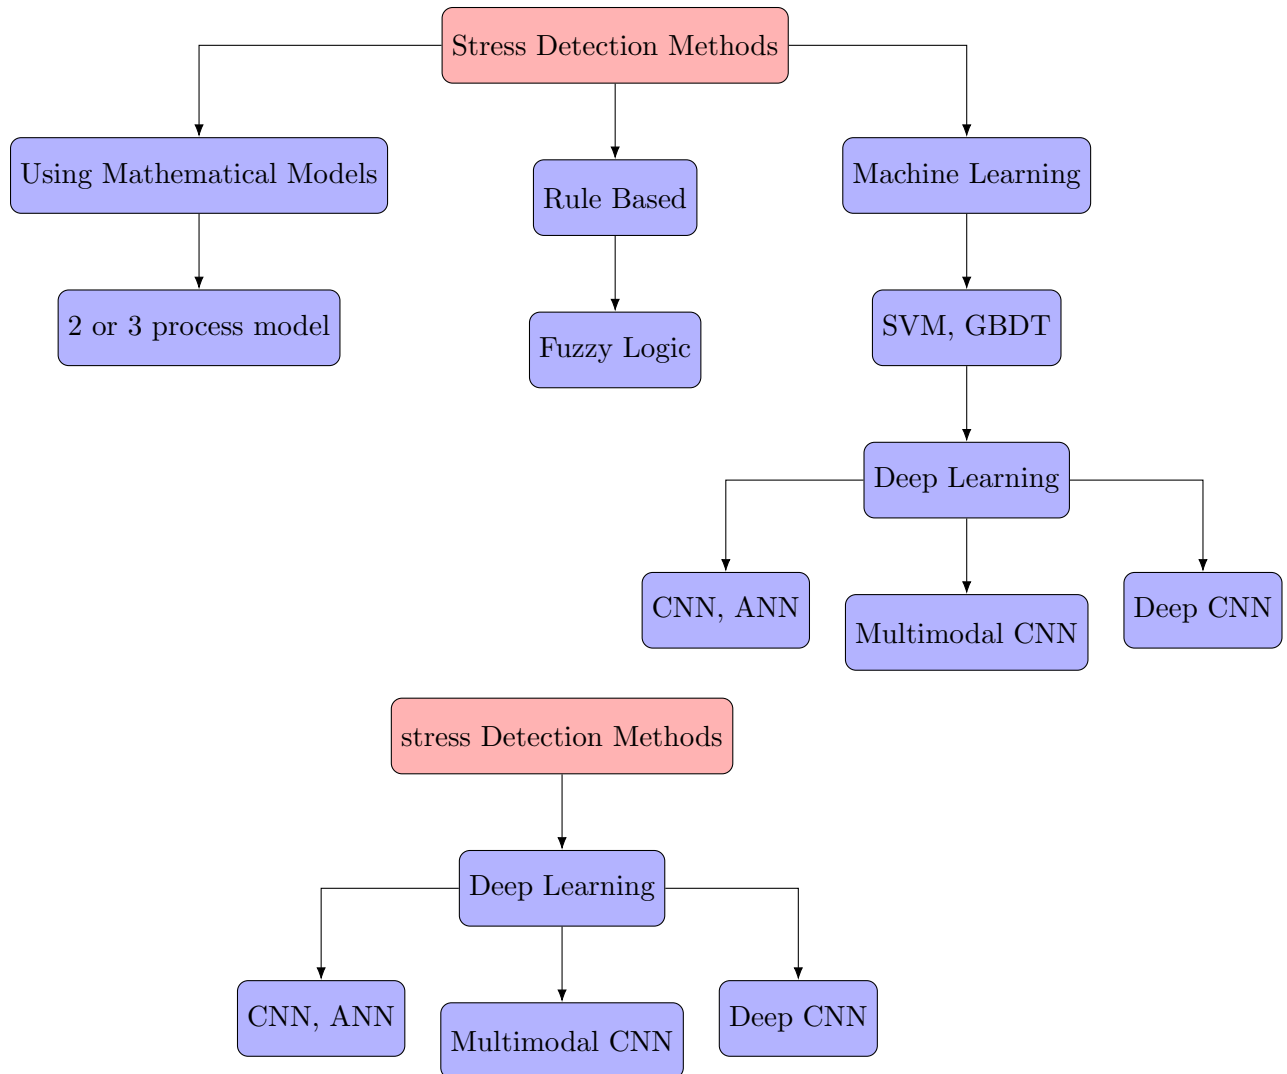


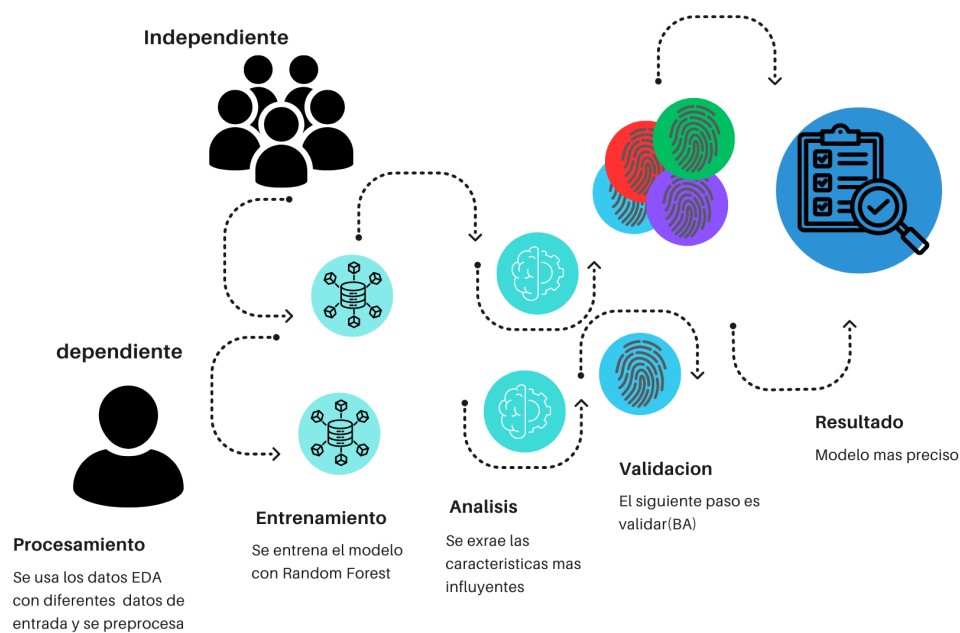
Tabla 3.1: Resumen de todas las metodologías para la detección de estrés .

Tipos de Características	Modelo de Extracción de Datos	Precisión	Datos
Detección de bostezos	Coeficientes de Gabor	95 %	400 images [Fan et al., 2007]
Estado del ojo	AdaBoost	90.18 %	2100 images [Wang et al., 2010]
Señales EEG	Árbol de Decisión Potenciado	95 %	Serie Temporal [Hu and Min, 2018]
Comportamiento facial	SVM	94.8 %	Imágenes iBUG 300-W [Sagonas et al., 2018]
registros EEG	Neural Network	83.6 %	del MIT-BIH [Administration et al., 2018]
EEG (Tiempo Real)	Linear Regression	90 %	Tiempo Real
Skin conductance	SVM	92.95 %	Imágenes [Bundele and Banerjee, 2009]
EDA	Estadístico basado en la excitación	79.17 %	Serie de Tiempo
EDA y audio	SVM y ANN	88.8 %	Wesad [Schmidt et al., 2018]
EEG	Autoencoder y DCT	100 %	[Rundo et al., 2019]
multimodal	modelo random forest-based mixed-effects,	0.75	[Bai et al., 2021a]
EDA+HR	AcRoNN	86.87 %	[Alam, 2021]
ECG, EDA, EMG, EEG	LSTM, RF	84.1 %	[Jaiswal et al., 2022]
EDA	ADA-bosst	97.03 %	[Hosseini et al., 2022]
ECG	CNN	98.57 %	WESAD [Ying and Hao, 2023]
Multimodal	SELF-CARE	94.12 %	WESAD [Rashid et al., 2023]

## Capítulo 4

# Propuesta

---



- **Preprocesamiento:** En esta etapa, se preparan los datos antes de alimentarlos al modelo de aprendizaje automático. Esto puede incluir: **Limpieza de datos:** Utilizando [Derdiyok et al., 2024] se eliminan valores atípicos, se completan los datos faltantes con interpolación lineal, se eliminan los datos inconsistentes. **Filtro:** Se aplica un filtro Butterworth low-pass filter de 5HZ. **Normalización:** Escalar los datos

para que tengan una escala similar Min-max scaling.

- **Detección de características:** Aquí se extraen características relevantes de los datos. Se usa técnicas como: CVxEDA: para separar los componentes de la señal EDA en componente tónico y fásico. También se extraen las características estadísticas
- **Entrenamiento y Clasificación:** Se divide los datos en entrenamiento y prueba. En esta etapa, se utilizan dos algoritmos, Random Forest y Redes neuronales, también se encuentran los óptimos Hyperparámetros con GridSearch. El modelo ajusta sus parámetros para minimizar el error en las predicciones.
- **Análisis:** Implica analizar la variabilidad de las propiedades estadísticas las diferencias y similitudes de los datasets.
- **Validación:** Se evalúa el rendimiento del modelo utilizando datos de prueba.

Se utiliza la Validación cruzada para evaluar el rendimiento de manera robusta. Se utilizan Métricas de evaluación como precisión, recall, y se compara con otros estudios similares.

Por tanto se propone el diseño de un sistema para la detección de estrés a partir de datos fisiológicos EDA de baja resolución.

### DatabaseWork3d

El conjunto de datos contiene muestras de situaciones de trabajo fatigantes y libres de estrés, proporciona una representación de varios niveles de estrés. El conjunto de datos se acompaña de metadatos y anotaciones extensas, que facilitan el análisis e interpretación en profundidad.

Contiene datos de actividad electrodérmica (EDA), presión volumétrica sanguínea (BVP), temperatura de la piel y acelerómetro (ACC). EDA se muestrea a 4 Hz y abarca aspectos de conductividad de la piel, fásicos y tónicos, que se distinguen por un umbral de aproximadamente 0,05 ms. La temperatura de la piel se registra constantemente a 4 Hz en grados Celsius. Los datos de presión arterial se derivan de la señal del pulso de

volumen sanguíneo (BVP) de 64 Hz. Los datos del acelerómetro se recopilan a 64 Hz para medir la fuerza gravitacional (g) en las tres dimensiones espaciales (x, y y z).

Estas señales se capturan utilizando sensores de pulsera Empatica E4 y se aplica una técnica de reducción de resolución (downsampling) para estandarizar las frecuencias, equilibrando un examen fisiológico exhaustivo. y seguimiento continuo de la actividad. La opción de reducción de resolución, que reduce todas las entradas a 4 Hz, garantiza un conjunto de datos consistente y efectivamente fusionado.




Figura 4.1: dataset work3d

## Database 2

Desde un primer momento se utilizara los conjuntos de datos WESAD, Work3d para probar las hipótesis. Los conjuntos de datos se utilizan para comparar estadísticamente la precisión de la detección de estrés de los modelos independientes y dependientes del usuario .

Conjunto de datos WESAD: El conjunto de datos publicado consiste en datos fisiológicos recopilados de 15 participantes bajo dos protocolos de estudio diferentes que incluían una combinación de condiciones de diversión/estrés/relajación.

Los archivos del dataset en su forma natural contienen información derivada que en este estudio se ignoraran : HR.csv, IBI.csv, tags.csv. El archivo info.txt contiene algunos detalles sobre el contenido de la carpeta. Los datos sin procesar del dispositivo E4 están contenidos en los siguientes archivos (en cada archivo, la primera línea se refiere a la marca de tiempo global del canal del sensor al inicio, la segunda línea se refiere a la frecuencia de muestreo del canal del sensor).

- ACC.csv: muestreado a 32 Hz. Las 3 columnas de datos se refieren a los 3 canales del acelerómetro. Los datos se proporcionan en unidades de 1/64 g.




Figura 4.2: Características

- BVP.csv: muestreado a 64 Hz. Datos de fotopletismógrafo (PPG).
- EDA.csv: muestreado a 4 Hz. Los datos se proporcionan en  $\mu S$ .
- TEMP.csv: muestreado a 4 Hz. Los datos se proporcionan en grados centígrados .

En el experimento ,el dispositivo E4 fue usado en el muñeca no dominante de los participantes. La tasa de muestreo de los diferentes sensores fue diferente. Tambien se registro modalidades de pulso de volumen sanguíneo (BVP) fisiológico de alta resolución, electrocardiograma (ECG), actividad electrodérmica (EDA), electromiograma (EMG), respiración (RESP), temperatura de la piel (TEMP) y movimiento (ACC) con el dispositivo llamado RespiBAN. Al mismo tiempo, también los participantes usaron la pulsera Empatica E4 para capturar datos EDA de baja frecuencia de muestreo .

#### 4.0.1. Preprocesamiento

##### Extracción estadística de características EDA

La señal EDA se filtró a través de un filtro Butterworth low-pass filter de cuarto orden de 5 Hz. Lo que significa que sólo la señal EDA de alta resolución de los datos de WESAD-Chest se preprocesa a través de el filtro antes de extraer las características . A continuación se extrajeron las características de Eda QUE comprender la respuesta de conducción cutánea (SCR ),nivel de conducción cutánea ,los picos de scr ,inicios scr ,y la amplitud scr. junto con las características estadísticas .El tamaño de ventana y el desplazamiento de ventana fueron de 60 segundos y 30 segundos respectivamente lo que significa que el modelo busca patrones de estrés después de cada 30 segundos mediante la observación de características estadísticas extraídas en el paso anterior en el intervalo de 60 segundos.

### 4.0.2. Entrenamiento

Utilizando las características estadísticas, se entreno un modelos de aprendizaje automatico para detectar estrés : RAndom Forest (RF),y multi- Perceptrón de capa (MLP), utilizando Grid Search .La estandarización de la característica se aplica para la entrada de MLP, ya que el modelo funcionan mejor con datos estandarizados. Se realizo la estrategia Leave-One-Group-Out (LOGO) para el modelo de detección de estrés independiente del usuario. Los datos de entrenamiento y prueba para el entrenamiento dependiente del usuario se dividen mediante stratified train-test split strategy (entrenamiento y prueba) cuyo tamaño de prueba es igual al 28,6 %

Tabla 4.1: Configuraciones de Grid Search de cinco modelos de Aprendizaje Automático utilizados al entrenar modelos de detección de estrés.

Modelo	Parámetros GridCV	Valores
RF	n.estimadores	500, 1000
	Mínimo de muestras para dividir	2, 4
	Mínimo de muestras por hoja	1, 4
	Peso de clase	Ninguno, balance
MLP	Tamaños de capas ocultas	64, 128, 256, 512

### 4.0.3. Análisis

Lo que se espera es que el modelo dependiente del usuario detecte estadísticamente patrones con mayor precisión que un modelo independiente del usuario,independientemente de la elección del modelo de aprendizaje automático. Se entrenaron 2 modelos independientes y 2 modelos dependientes configurando LOGO junto con GridsearH,la métrica BA son calculados para cada individuo en cada Dataset para crear puntuaciones de evaluación de los modelos independientes y dependientes del usuario respectivamente. Los datos contienen  $2 \times 2 (\text{número de modelos}) \times 35$  observaciones para ambas salidas ,modelos dependientes y independientes del usuario. Cada uno consta de resultados independientes de 2 modelos de aprendizaje automático x35 datos de participantes en 2 conjuntos de datos .

En el experimentos, nos enfocamos en cubrir el análisis usando estadística inferencial,sobre la población utilizando un número de muestras representativas. Se utiliza , la

prueba de hipótesis para estimar el desempeño estadístico de los modelos de detección de estrés independientes y dependientes del usuario.

A partir de este punto, las hipótesis nula y alternativa de la prueba unilateral de suma de rangos se establecen de la siguiente manera:

- $H_0 : M_1 = M_2$  (El modelo dependiente del usuario no mejora en distinguir patrones estresantes y no estresantes).
- $H_a : M_1 \neq M_2$  (El modelo dependiente del usuario logra distinguir patrones de estrés/no estrés de forma más precisa que uno independiente del usuario).

donde ,  $M_1$  y  $M_2$  indican la mediana de las puntuaciones de precisión de la predicción de estrés/sin estrés de los modelos dependientes e independientes del usuario.



# Capítulo 5

## Experimentos y Resultados

En este trabajo, se considero los datos de uso en el pecho como WESAD-Chest y los datos de uso en la muñeca como WESAD-Wrist.




Figura 5.1: resultados

### 5.0.1. Métricas

La mayoría de estos conjuntos de datos tienen un números desigual de etiquetas de estrés/no estrés,por lo que usar la precisión como se uso en otros trabajos no es adecuado,para evitar sesgos se elige una métrica de evaluación basada en el estudio

---

Figura 5.2: Ejemplo del *aliasing* que se produce en una grilla con  $N = 8$  nodos. Ambos modos ( $k = 2$  y  $k = 10$ ) toman los mismos valores en los puntos de la grilla.

de Sirko Straube et al. [Sirko Straube et al, 2020], donde establece que la precisión equilibrada (BA) es una opción adecuada para evaluar los resultados, ya que se quiere evaluar la capacidad de distinguir las dos categorías para evaluar solamente la precisión de detectar patrones de estrés.

## Capítulo 6

# Conclusiones y trabajo futuro

---

Los modelos dependientes del usuario son mas preciso que los modelos independientes del usuario La conclusión está respaldada por las puntuaciones de BA del modelo de detección de estrés entrenado

# Bibliografía

- [Administration et al., 2011] Administration, N. H. T. S. et al. (2011). Fars data tables.
- [Alam, 2021] Alam, M. A. U. (2021). Activity-aware deep cognitive fatigue assessment using wearables. In *2021 43rd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*, pages 7433–7436. IEEE.
- [Bai et al., 2021a] Bai, Y., Guan, Y., Shi, J. Q., and Ng, W. (2021a). Towards automated fatigue assessment using wearable sensing and mixed-effects models. In *Proceedings of the 2021 ACM International Symposium on Wearable Computers, ISWC '21*, page 129–131, New York, NY, USA. Association for Computing Machinery.
- [Bai et al., 2021b] Bai, Y., Guan, Y., Shi, J. Q., and Ng, W.-F. (2021b). Towards automated fatigue assessment using wearable sensing and mixed-effects models. In *Proceedings of the 2021 ACM International Symposium on Wearable Computers*, pages 129–131.
- [Brown and Bray, 2019] Brown, D. M. and Bray, S. R. (2019). Effects of mental fatigue on exercise intentions and behavior. *Annals of Behavioral Medicine*, 53(5):405–414.
- [Bundeale and Banerjee, 2009] Bundeale, M. M. and Banerjee, R. (2009). An svm classifier for fatigue-detection using skin conductance for use in the bits-lifeguard wearable computing system. In *2009 Second International Conference on Emerging Trends in Engineering & Technology*, pages 934–939. IEEE.
- [Cropanzano et al., 2003] Cropanzano, R., Rupp, D. E., and Byrne, Z. S. (2003). The relationship of emotional exhaustion to work attitudes, job performance, and organizational citizenship behaviors. *Journal of Applied psychology*, 88(1):160.
- [Derdiyok et al., 2024] Derdiyok, S., Akbulut, F. P., and Catal, C. (2024). Neurophysiological and biosignal data for investigating occupational mental fatigue: Mefar dataset. *Data in Brief*, 52:109896.
- [Devi and Bajaj, 2010] Devi, M. S. and Bajaj, P. R. (2010). Fuzzy based driver fatigue detection. In *2010 IEEE International Conference on Systems, Man and Cybernetics*, pages 3139–3144. IEEE.
- [Dogan and Akbulut, 2023] Dogan, G. and Akbulut, F. P. (2023). Multi-modal fusion learning through biosignal, audio, and visual content for detection of mental stress. *Neural Computing and Applications*, 35(34):24435–24454.

- [Du et al., 2017] Du, L.-H., Liu, W., Zheng, W.-L., and Lu, B.-L. (2017). Detecting driving fatigue with multimodal deep learning. In *2017 8th International IEEE/EMBS Conference on Neural Engineering (NER)*, pages 74–77. IEEE.
- [Fan et al., 2007] Fan, X., Yin, B.-C., and Sun, Y.-F. (2007). Yawning detection for monitoring driver fatigue. In *2007 International Conference on Machine Learning and Cybernetics*, volume 2, pages 664–668. IEEE.
- [Grillon et al., 2015] Grillon, C., Quispe-Escudero, D., Mathur, A., and Ernst, M. (2015). Mental fatigue impairs emotion regulation. *Emotion*, 15(3):383.
- [Hockey, 1983] Hockey, R. (1983). Stress and fatigue in human performance. (*No Title*).
- [Hosseini et al., 2022] Hosseini, E., Fang, R., Zhang, R., Parenteau, A., Hang, S., Rafatirad, S., Hostinar, C., Orooji, M., and Homayoun, H. (2022). A low cost eda-based stress detection using machine learning. In *2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, pages 2619–2623.
- [Hu and Min, 2018] Hu, J. and Min, J. (2018). Automated detection of driver fatigue based on eeg signals using gradient boosting decision tree model. *Cognitive neurodynamics*, 12:431–440.
- [Ishii et al., 2014] Ishii, A., Tanaka, M., and Watanabe, Y. (2014). Neural mechanisms of mental fatigue. *Reviews in the Neurosciences*, 25(4):469–479.
- [Jaiswal et al., 2022] Jaiswal, A., Zadeh, M. Z., Hebri, A., and Makedon, F. (2022). Assessing fatigue with multimodal wearable sensors and machine learning. *ArXiv*, abs/2205.00287.
- [Marcora et al., 2009] Marcora, S. M., Staiano, W., and Manning, V. (2009). Mental fatigue impairs physical performance in humans. *Journal of applied physiology*.
- [Martin et al., 2018] Martin, K., Meeusen, R., Thompson, K. G., Keegan, R., and Rattray, B. (2018). Mental fatigue impairs endurance performance: a physiological explanation. *Sports medicine*, 48(9):2041–2051.
- [Meijman, 2000] Meijman, T. (2000). The theory of the stop-emotion: On the functionality of fatigue. In *2nd International Conference on Ergonomics and Safety for Global Business Quality and Productivity*, pages 45–47. CENT INST LABOUR PROTECT.
- [Rashid et al., 2023] Rashid, N., Mortlock, T., and Al Faruque, M. A. (2023). Stress detection using context-aware sensor fusion from wearable devices. *IEEE Internet of Things Journal*.
- [Rundo et al., 2019] Rundo, F., Rinella, S., Massimino, S., Coco, M., Fallica, G., Parenti, R., Conoci, S., and Perciavalle, V. (2019). An innovative deep learning algorithm for drowsiness detection from eeg signal. *Computation*, 7(1).
- [Sagonas et al., 2016] Sagonas, C., Antonakos, E., Tzimiropoulos, G., Zafeiriou, S., and Pantic, M. (2016). 300 faces in-the-wild challenge: Database and results. *Image and vision computing*, 47:3–18.

- [Schmidt et al., 2018] Schmidt, P., Reiss, A., Dürichen, R., Marberger, C., and Laerhoven, K. V. (2018). Introducing wesad, a multimodal dataset for wearable stress and affect detection. *Proceedings of the 20th ACM International Conference on Multimodal Interaction*.
- [Sikander and Anwar, 2018] Sikander, G. and Anwar, S. (2018). Driver fatigue detection systems: A review. *IEEE Transactions on Intelligent Transportation Systems*, 20(6):2339–2352.
- [Van Cutsem et al., 2017] Van Cutsem, J., Marcora, S., De Pauw, K., Bailey, S., Meeusen, R., and Roelands, B. (2017). The effects of mental fatigue on physical performance: a systematic review. *Sports medicine*, 47:1569–1588.
- [Wang et al., 2010] Wang, H., Zhou, L., and Ying, Y. (2010). A novel approach for real time eye state detection in fatigue awareness system. In *2010 IEEE Conference on Robotics, Automation and Mechatronics*, pages 528–532. IEEE.
- [Ying and Hao, 2023] Ying, G. and Hao, C. (2023). A novel one-dimensional convolutional neural network-based method for emotion recognition of electric power industry workers. *Energy Reports*, 9:763–771. 2022 The 3rd International Conference on Power Engineering.